**공통 파트**

**True DGP**

$$Y = m(\underline{X}) + \sigma_0(\underline{X})\epsilon, \qquad X_1,\ X_2 \overset{iid}{\sim} U(-1,1)$$

↓

| 행 | $x_1$ | $x_2$ | $y$ |
|---|---|---|---|
| 1 | | | |
| ⋮ | | | |
| 1000 | | | |

Training dataset

$$D_{train} = \{(\underline{X}_j^{train}, Y_j^{train})\}_{j=1}^{1000}$$

$$Y_j^{train} = m(\underline{X}_j^{train}) + \sigma_0(\underline{X}_j^{train})\epsilon_j^{train}$$

↓

**Random Forest 학습**

$$\hat{f} = Fit(D_{train})$$

↓

**잔차로 분산 추정**

$$r_j = Y_j^{train} - \widehat{f}(\underline{X}_j^{train}), \qquad r_j \to \hat{\sigma}^2$$

200회 반복 동안 고정

$D_{train}$, $\hat{f}$, $\hat{\sigma}^2$, $\{\underline{x}_i\}_{i=1}^{25}$ : grid하게 평가할 test

매 반복 $r = 1, \ldots, 200$

**Grid test 25개**

$$\underline{x}_i \in \{-1, -0.5, 0, 0.5, 1\}^2, \qquad i = 1, \ldots, 25$$

$$Y_i^{grid,(r)} = m(\underline{x}_i) + \sigma_0(\underline{x}_i)\epsilon_i^{grid,(r)}$$

입력 벡터 $\underline{x}_i$는 고정, $Y$만 새로 생성

**Conformal Prediction 파트**

매 반복 $r = 1, \ldots, 200$

**1. True DGP에서 독립 Calibration 생성**

| 행 | $x_1$ | $x_2$ | $y$ |
|---|---|---|---|
| 1 | | | |
| ⋮ | | | |
| 1000 | | | |

Calibration dataset

$$D_{cal}^{(r)} = \{(\underline{X}_a^{cal,(r)}, Y_a^{cal,(r)})\}_{a=1}^{1000}$$

$$Y_a^{cal,(r)} = m(\underline{X}_a^{cal,(r)}) + \sigma_0(\underline{X}_a^{cal,(r)})\epsilon_a^{cal,(r)}$$

**2. 절대잔차 score 계산**

$$S_a^{(r)} = |Y_a^{cal,(r)} - \hat{f}(\underline{X}_a^{cal,(r)})|$$

**3. Score 정렬 → conformal 순위 · 분위수**

$$k_\alpha = \lceil (n_{cal}+1)(1-\alpha) \rceil, \qquad \hat{q}_\alpha^{(r)} = S_{(k_\alpha)}^{(r)}$$

$n_{cal} = 1,000 \rightarrow$ 90% : 901번째 / 95% : 951번째

**4. Grid와 무작위 test의 입력 벡터에서 구간 생성**

Grid의 고정 입력 벡터 $\underline{x}_i$ 25개 위치

$$C_{CP,\alpha}^{(r)}(\underline{x}_i) = [\hat{f}(\underline{x}_i) - \hat{q}_\alpha^{(r)},\ \hat{f}(\underline{x}_i) + \hat{q}_\alpha^{(r)}]$$

**5. 실제 test $Y$의 포함 여부를 각각 기록**

$$I_{CP,i,r,\alpha}^{grid} = 1\{Y_i^{grid,(r)} \in C_{CP,\alpha}^{(r)}(\underline{x}_i)\}$$

$$I_{CP,t,r,\alpha}^{test} = 1\{Y_t^{test,(r)} \in C_{CP,\alpha}^{(r)}(\underline{X}_t^{test,(r)})\}$$

**Monte Carlo 파트**

매 반복 $r = 1, \ldots, 200$

**1. 가상 training dataset 200개 생성**

$$Y_j^{*(r,b)} = \hat{f}(\underline{X}_j^{train}) + \epsilon_j^{*(r,b)}, \qquad \epsilon_j^{*(r,b)} \sim N(0, \hat{\sigma}^2)$$

| 행 | $x_1$ | $x_2$ | $y^*$ |
|---|---|---|---|
| 1 | | | |
| ⋮ | | | |
| 1000 | | | |

가상 데이터셋 1

$$\cdots$$

$$D^{*(r,b)} = \{(\underline{X}_j^{train}, Y_j^{*(r,b)})\}_{j=1}^{1000}$$

| 행 | $x_1$ | $x_2$ | $y^*$ |
|---|---|---|---|
| 1 | | | |
| ⋮ | | | |
| 1000 | | | |

가상 데이터셋 200

**2. 각 데이터셋으로 재학습**

$$\hat{f}^{*(r,1)} = Fit(D^{*(r,1)}) \qquad \hat{f}^{*(r,200)} = Fit(D^{*(r,200)})$$

**3. 같은 모델 200개로 모든 test 입력 벡터에서 예측**

Grid 25개 + 무작위 test 1,000개

$$\hat{y}^{*(r,b)}(\underline{x}) = \hat{f}^{*(r,b)}(\underline{x})$$

**4. 예측값에 독립적인 새 관측오차 추가**

$$\widetilde{Y}^{*(r,b)}(\underline{x}) = \hat{y}^{*(r,b)}(\underline{x}) + \epsilon_{new}^{*(r,b)}(\underline{x}), \qquad \epsilon_{new}^{*(r,b)} \sim N(0, \hat{\sigma}^2)$$

새 오차는 반복(r) · 모델(b) · 평가 입력 벡터마다 독립 생성

**5. $\underline{x}$ 마다 가상 새 반응값 200개의 분위수로 구간 생성**

$$\mathcal{P}^{(r)}(\underline{x}) = \{\widetilde{Y}^{*(r,b)}(\underline{x})\}_{b=1}^{200}$$

$$C_{MC,\alpha}^{(r)}(\underline{x}) = [Q_{\alpha/2}\{\mathcal{P}^{(r)}(\underline{x})\},\ Q_{1-\alpha/2}\{\mathcal{P}^{(r)}(\underline{x})\}]$$

**6. 실제 test $Y$의 포함 여부를 각각 기록 → grid · marginal 집계는 다음 페이지**

Grid의 포함 여부

$$I_{MC,i,r,\alpha}^{grid} = 1\{Y_i^{grid,(r)} \in C_{MC,\alpha}^{(r)}(\underline{x}_i)\}$$

가상 반응값은 구간 생성용 / 실제 평가 $Y$ 는 true DGP에서 독립 생성

**평가 파트**

## Grid : 입력 벡터 $\underline{x}_i$ 별 conditional coverage

$$P(Y_{test} \in C(\underline{X}_{test}) | \underline{X}_{test} = \underline{x})$$

하나의 입력 벡터 $\underline{x}_i$ 를 200회 내내 고정

$$\underline{x}_i \in \{-1, -0.5, 0, 0.5, 1\}^2, \qquad i = 1, \ldots, 25$$

↓

매 반복 새 $Y$ 생성

$\underline{x}_i$ 에서 만든 MC · CP 구간과 비교

↓

입력 벡터 $\underline{x}_i$ 하나에 대한 기록 예시

| 반복 $r$ | 같은 $\underline{x}_i$ 에서 새 $Y$ 의 포함 여부 |
|---|---|
| 1 | 1 |
| 2 | 0 |
| ⋯ | ⋯ |
| 200 | 1 |

↓

같은 $\underline{x}_i$ 에서 기록한 0 · 1을 200회 평균

$$\hat{c}_{h,\alpha}(\underline{x}_i) = \frac{1}{200} \sum_{r=1}^{200} I_{h,i,r,\alpha}^{grid}$$

예 : 190회 포함 / 200회 = 0.95

**결과 : 입력 벡터 $\underline{x}_i$ 별 coverage 25개**

어떤 입력 벡터 $\underline{x}_i$ 에서 잘되거나 실패하는가

$$h \in \{MC,\ CP\}$$

Training은 고정 / CP의 marginal 평가도 calibration과 test를 함께 반복